Projeto Integrador
Engenharia da Computação (D009351)

+ + + +

USO DE INTELIGÊNCIA ARTIFICIAL NA DESCARBONIZAÇÃO

Professor: Leonardo Pereira Valadão Lopes

Apresentação gerada a partir do trabalho realizado na disciplina optativa do semestre 2025/01

IA PARA DETECÇÃO E MONITORAMENTO DE VAZAMENTO DE GÁS EM PLATAFORMA DE PETRÓLEO

FAESA
CENTRO UNIVERSITÁRIO

Flare (20%)

Refere-se à queima controlada de gases, geralmente gás natural ou gás associado ao petróleo, que não podem ser utilizados ou processados de forma segura.

Geração de Energia (70%)

Geradores a diesel ou gás que fornecem energia elétrica necessária para operar os equipamentos, sistemas de perfuração, iluminação, e outros serviços essenciais.



Venting and Fugitivas (10%)

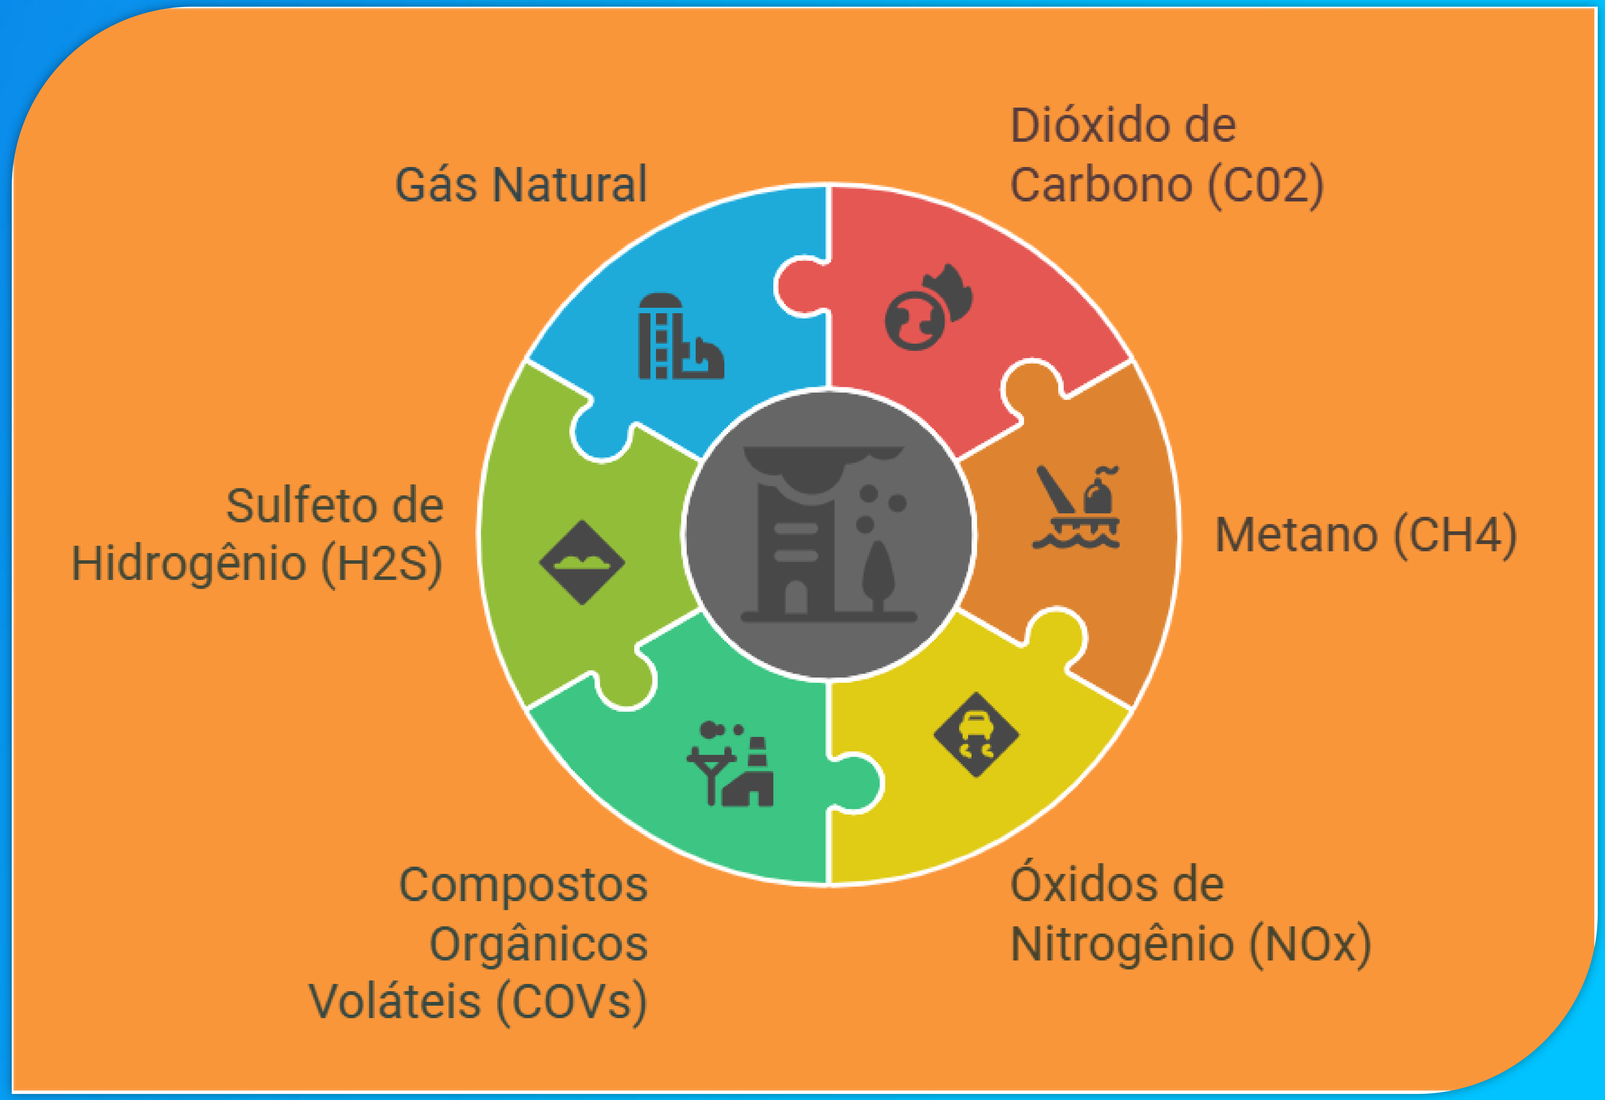
Refere-se à liberação “intencional” de gases, diretamente na atmosfera, sem que esses gases sejam capturados ou utilizados.

Fonte: Petrobras

CONTEXTUALIZAÇÃO DO PROBLEMA: PRINCIPAIS FONTES DE EMISSÃO (GEE)

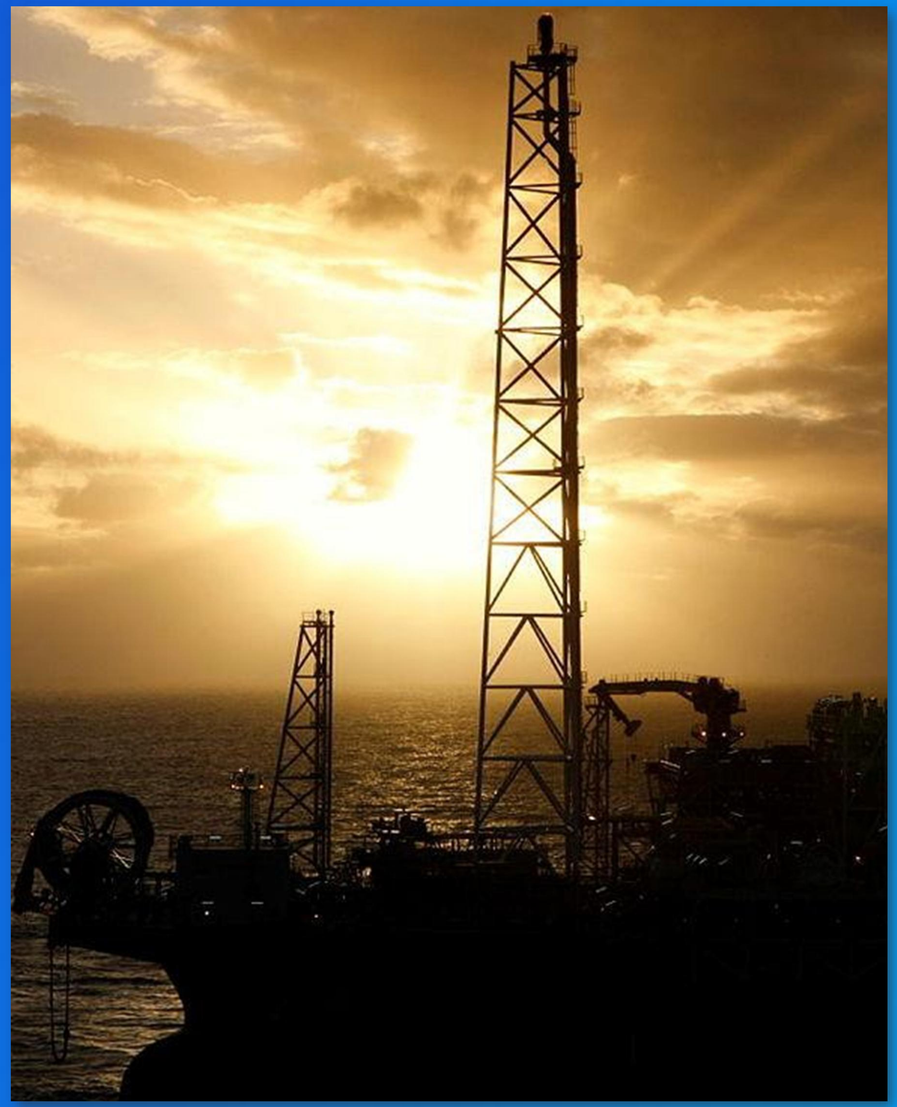
FAESA CENTRO UNIVERSITÁRIO





CONTEXTUALIZAÇÃO DO PROBLEMA: PRINCIPAIS GASES PRODUZIDOS NA INDÚSTRIA DO PETRÓLEO

FAESA CENTRO UNIVERSITÁRIO





Comissionamento
(I.03)

Evento em sistema de compressão

Queima rotineira

Passagem em válvulas

Evento em sistema de medição

Evento em FGRU

Parada Geral de emergência

CONTEXTUALIZAÇÃO DO PROBLEMA: EVENTOS DOS PRINCIPAIS OFENSORES

FAESA
CENTRO UNIVERSITÁRIO



1. Tubulação;
2. Flange;
3. Válvulas;
4. Instrumentos;
5. Equipamentos;
6. Selos de bomba;
7. Juntas;
8. Interseções;
9. Válvulas de Alívio;
10. Conexões rápidas;

CONTEXTUALIZAÇÃO DO PROBLEMA: PONTOS DE VAZAMENTO (EMISSÕES FUGITIVAS)

FAESA
CENTRO UNIVERSITÁRIO



Detector de Gás Portátil (Lapela)



Detector de Gás Ultrasson



Sensores Eletroquímicos



Detector de Gás Fixo



Analisador de metano fugitivo

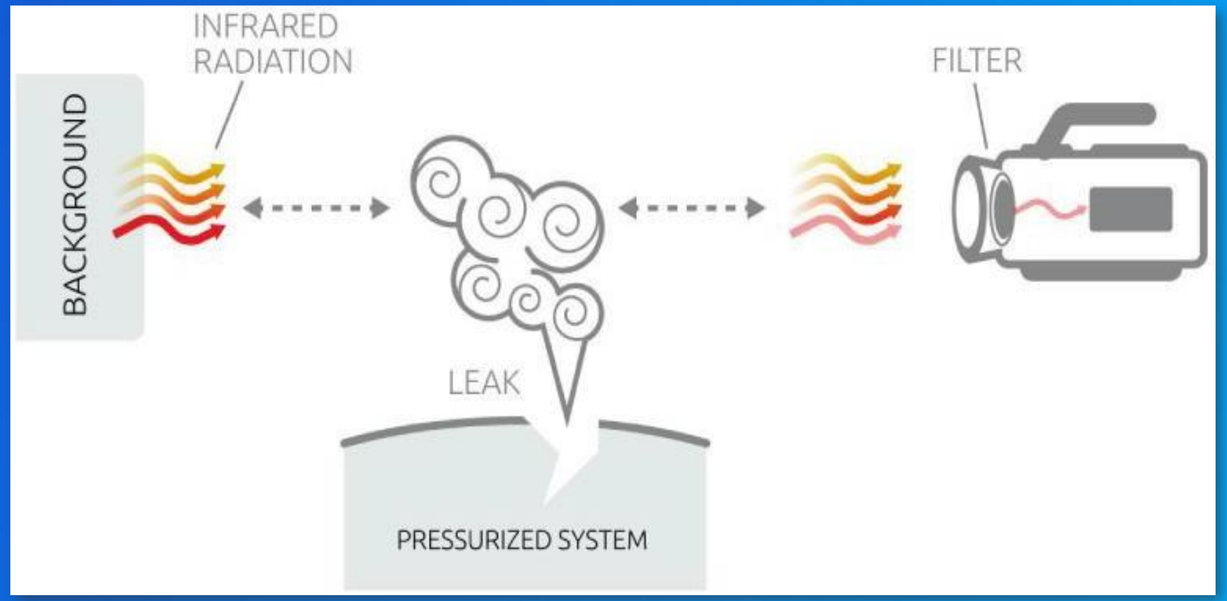
BENCHMARK: TECNOLOGIAS ENVOLVIDAS

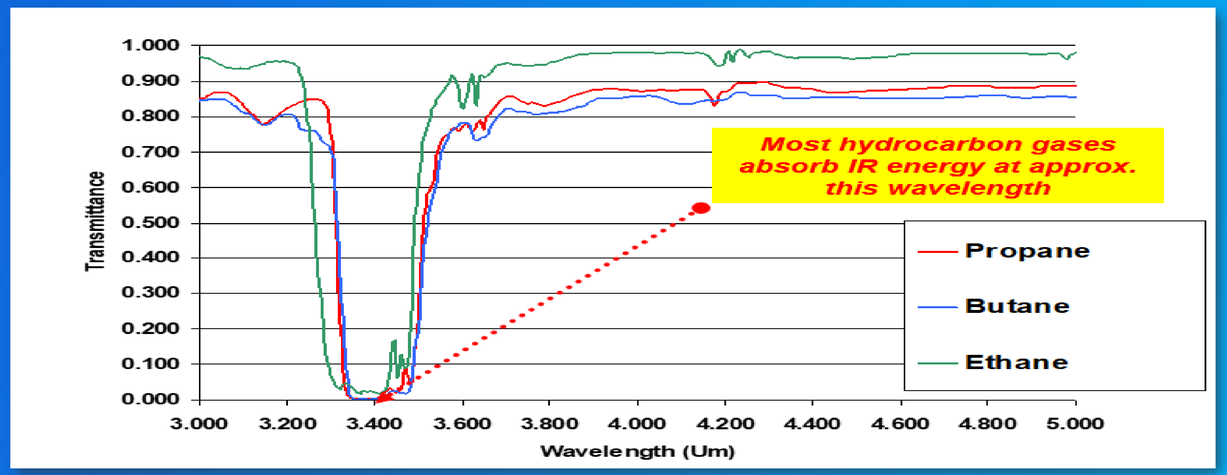
FAESA
CENTRO UNIVERSITÁRIO



BENCHMARK: TECNOLOGIAS ENVOLVIDAS

FAESA
CENTRO UNIVERSITÁRIO





O princípio de funcionamento de uma câmera OGI (Optical Gas Imaging) baseia-se na detecção de radiação infravermelha emitida por gases e vapores.

Essas câmeras são sensíveis a diferentes comprimentos de onda da radiação infravermelha, que é emitida por objetos e substâncias em função de sua temperatura.

Quando um gás está presente em um ambiente, ele pode ter uma temperatura diferente da do ar circundante, e essa diferença gera um contraste que a câmera consegue captar, permitindo a sua visualização.

1. **Detecção de Radiação Infravermelha:** A câmera possui sensores que detectam a radiação infravermelha emitida pelos objetos na cena;

2. **Conversão de Sinal:** Os sensores convertem a radiação em um sinal elétrico;

3. **Processamento de Imagem:** O sinal elétrico é processado para criar uma imagem térmica. Essa imagem mostra diferentes temperaturas com cores diferentes, facilitando a visualização de variações térmicas;

4. **Exibição da Imagem:** A imagem térmica é exibida em uma tela, onde os usuários podem interpretar as temperaturas dos objetos na cena.



BENCHMARK: TECNOLOGIAS ENVOLVIDAS
FUNCIONAMENTO DE UMA CÂMERA TÉRMICA

FAESA
CENTRO UNIVERSITÁRIO

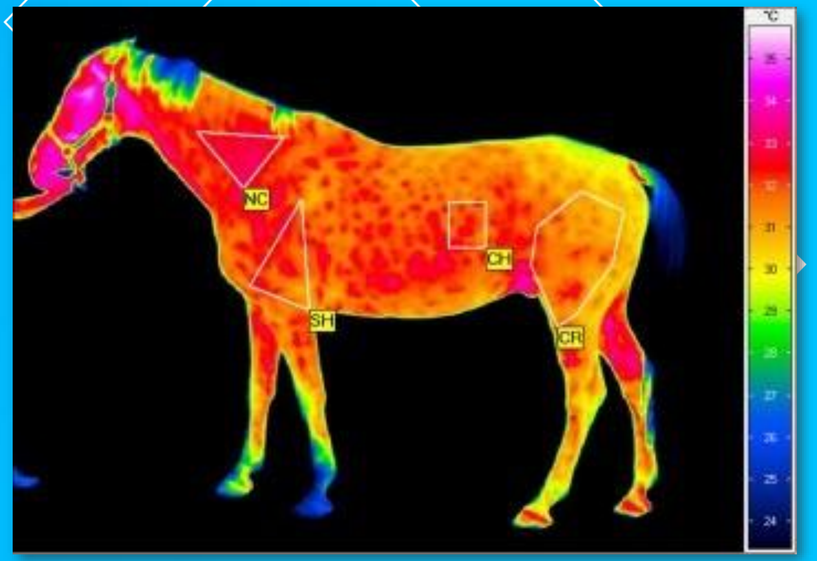
VIDEOMONITORAMENTO



INDÚSTRIA ELÉTRICA



MEDICINA VETERINÁRIA



IMAGENS GERADAS - APLICAÇÕES

FAESA
CENTRO UNIVERSITÁRIO



VIDEOS GERADOS PELA CÂMERA OGI

FAESA
CENTRO UNIVERSITÁRIO

MENU g1 RIO DE JANEIRO BUSCAR

Plataforma de petróleo pega fogo na Bacia de Campos, e 14 funcionários ficam feridos

O Sindipetro-NF informou que o incidente ocorreu por volta das 7h25, e as chamas foram rapidamente controladas. Um trabalhador chegou a cair no mar e foi resgatado com queimaduras.

Por Mylena Rodrigues, Josué Amador, Intertv e g1 Rio

21/04/2025 10h18 · Atualizado há 2 semanas

Nota da Petrobras

"Com relação ao incêndio, já debelado na manhã desta segunda-feira (21/04), na plataforma PCH-1 (Cherne 1), na Bacia de Campos, a cerca de 130 km da costa de Macaé, no Rio de Janeiro, a Petrobras informa que o trabalhador resgatado no mar se encontra em atendimento hospitalar em terra, consciente e estável. Outros 13 trabalhadores que prestam serviço para a companhia foram classificados como feridos e também estão recebendo atendimento em hospital da região.

A plataforma não produz petróleo desde 2020. As demais pessoas que estão a bordo de PCH-1 estão bem. Uma comissão será formada para apurar as causas do incidente."



Fonte: https://g1.globo.com/rj/rio-de-janeiro/noticia/2025/04/21/plataforma-de-petroleo-campos.ghtml

DESAFIOS

FAESA CENTRO UNIVERSITÁRIO

1. Identificação da melhor ferramenta e técnica para o desenvolvimento do algoritmo;

2. Coleta de dados para treinamento do modelo e simulação de cenários;

1. Identificação da melhor ferramenta e técnica para o desenvolvimento do algoritmo;

Técnica de Visão Computacional:

- ✓ Ambiente de desenvolvimento: **Google Colab**
- ✓ Framework: ***Darknet*** → ***Ultralytics***
- ✓ Biblioteca: **OpenCV**
- ✓ Algoritmo: **YOLOv4** → **YOLOv8s**

2. Coleta de dados para treinamento do modelo e simulação de cenários;

Dados Públicos:

- ✓ ***TensorFlow;***
- ✓ ***Catalyser;***
- ✓ ***Google APIs;***
- ✓ ***ImageNet;***
- ✓ ***Kaggle;***
- ✓ ***GitHub;***
- ✓ ***Roboflow (anotação e datasets).***





YOLO – EXEMPLOS DE RESULTADOS

FAESA
CENTRO UNIVERSITÁRIO





YOLO – EXEMPLOS DE RESULTADOS

FAESA
CENTRO UNIVERSITÁRIO

Da câmera OGI ao alerta de vazamento

1 — Coleta

Quadros extraídos de vídeos públicos de câmeras OGI (infravermelho)

2 — Anotação

Caixas delimitadoras no Roboflow, classe única gasleak

3 — Treinamento

YOLOv8s no Google Colab com GPU, até 500 épocas

4 — Validação

Precisão, recall e mAP medidos a cada época

5 — Inferência

Detecção em imagens, vídeos e câmera ao vivo (best.pt ou ONNX)

6 — Alerta

Caixa e confiança sinalizam o vazamento para a operação

Ferramentas: Google Colab · Google Drive · Roboflow · Ultralytics YOLOv8 · OpenCV · ONNX

SOLUÇÃO PROPOSTA:
PIPELINE DO PROJETO

FAESA
CENTRO UNIVERSITÁRIO

Duas gerações de detector para o mesmo problema

1ª VERSÃO

YOLOv4 + Darknet

- Framework Darknet (C/CUDA) e inferência com o módulo DNN do OpenCV
- Backbone CSPDarknet53 + SPP, neck PANet e detecção com caixas-âncora
- Entrada 608 × 608, lote 64, 1 classe
- Dataset preparado com scripts próprios: conversão das anotações e listas de treino e teste

VERSÃO FINAL

YOLOv8s + Ultralytics

- Framework Ultralytics (PyTorch), tudo em Python
- Backbone com blocos C2f e SPPF, neck PAN-FPN e cabeça desacoplada sem âncoras
- Entrada 640 × 640, lote 16, 1 classe (gasleak)
- Treino, validação, gráficos e exportação para ONNX no mesmo fluxo

Por que migrar: menos etapas manuais, treino mais rápido no Colab, métricas automáticas a cada época e exportação para ONNX.

Base própria construída a partir de vídeos OGI

539

imagens anotadas

575

caixas de vazamento

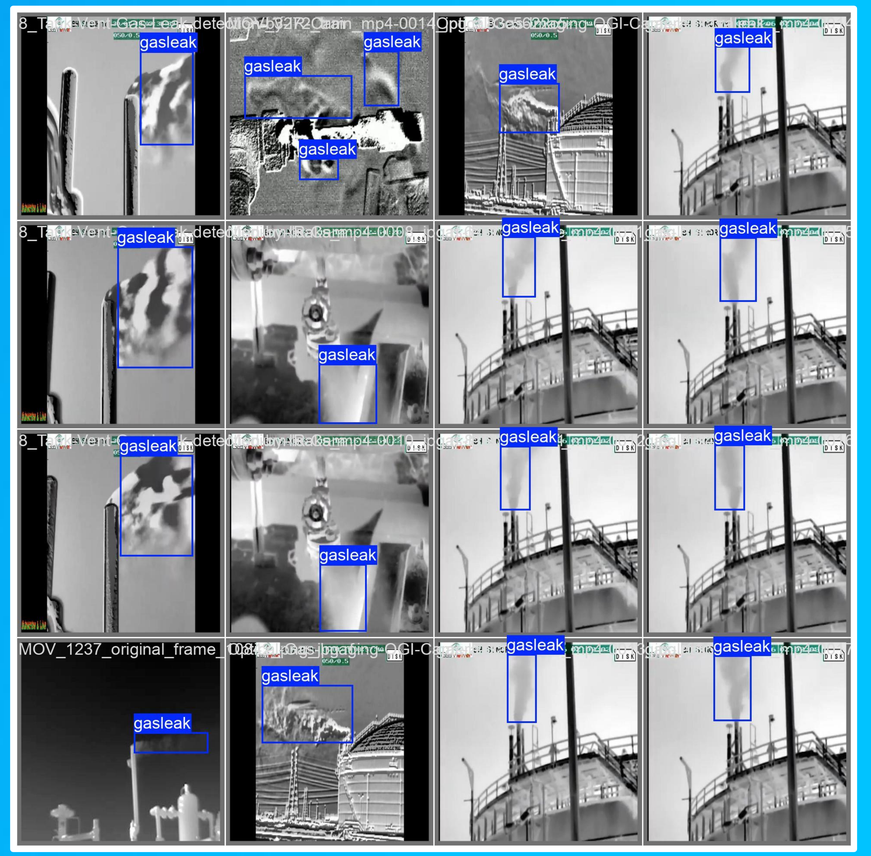
395 · 144

treino · validação

1

classe: gasleak

- Quadros de cerca de 100 vídeos e imagens de câmeras OGI, anotados no Roboflow (formato YOLO: centro, largura e altura normalizados)
- Aumento de dados a cada lote: mosaico de 4 imagens, variação de cor (HSV), espelhamento horizontal, translação (±10%) e escala (±50%)



Lote de validação com as caixas anotadas

TREINAMENTO:
DATASET

FAESA
CENTRO UNIVERSITÁRIO

YOLOv8s: detector de estágio único, sem âncoras

Entrada

640 × 640 × 3

- Quadro da câmera ou imagem
- Redimensionado com letterbox
- Pixels normalizados (0 a 1)

Backbone

CSPDarknet com C2f

- Conv 3×3 + BatchNorm + SiLU
- 4 estágios com blocos C2f
- SPPF ao final
- Mapas P3, P4 e P5 (stride 8, 16 e 32)

Neck

PAN-FPN

- Caminho top-down (FPN) leva contexto às camadas de alta resolução
- Caminho bottom-up (PAN) devolve detalhe espacial
- Saídas 80×80, 40×40 e 20×20

Head

Sem âncoras

- Ramos separados para caixa e classe
- Caixa: 4 lados × 16 bins (DFL)
- Classe: 1 saída (gasleak)
- 8.400 predições por imagem

Saída

NMS · IoU 0,7

- Caixa + confiança
- Limiar 0,5 (imagens) e 0,4 (vídeos)

≈ 11,1 M
parâmetros treináveis

≈ 28
GFLOPs por imagem de 640 px

0,33 · 0,50
profundidade · largura (escala s)

22 MB
pesos best.pt em FP16

TREINAMENTO:
ARQUITETURA YOLOv8s

FAESA
CENTRO UNIVERSITÁRIO

Componentes-chave do YOLOv8

1 C2f

Bloco CSP com dois ramos e vários gargalos (bottlenecks) concatenados: mais fluxo de gradiente com custo computacional baixo.

2 SPPF

Três max-poolings 5×5 em sequência ampliam o campo receptivo, útil para plumas de tamanhos muito diferentes.

3 PAN-FPN

Combina mapas de alta e baixa resolução para detectar plumas pequenas e distantes e nuvens grandes e próximas.

4 Cabeça sem âncoras

Classificação e regressão em ramos separados; o modelo prevê as distâncias do centro às bordas, sem caixas-âncora.

5 TaskAlignedAssigner

Escolhe as predições positivas combinando a confiança da classe e o IoU com a caixa real (10 melhores por objeto).

6 Função de perda

Caixa: CIoU (peso 7,5) + Distribution Focal Loss (peso 1,5). Classe: entropia cruzada binária (peso 0,5).

Treino no Google Colab com GPU

Modelo	YOLOv8s (yolov8s.yaml), pesos iniciados do zero
Épocas	500 planejadas, early stopping com paciência 100
Lote e entrada	16 imagens · 640 × 640 px
Otimizador	AdamW (seleção automática do Ultralytics)
Taxa de aprendizado	0,002 → 0,00002 (decaimento linear)
Momentum · weight decay	0,9 · 0,0005
Warm-up	3 épocas
Precisão mista	AMP ativada (FP16)
Aumento de dados	mosaico, HSV, espelhamento, translação, escala
Hardware e tempo	GPU do Google Colab · cerca de 76 min

EARLY STOPPING

Parada antecipada



- De 500 épocas planejadas, o treino parou na 475
- A aptidão (0,1·mAP@50 + 0,9·mAP@50-95) não melhorou por 100 épocas após a 375
- O best.pt salvo é o da época 375
- Cerca de 9,6 s por época

Melhor modelo: época 375

90,5%

Precisão

das detecções, quantas eram vazamento

78,9%

Recall

dos vazamentos reais, quantos foram detectados

86,6%

mAP@50

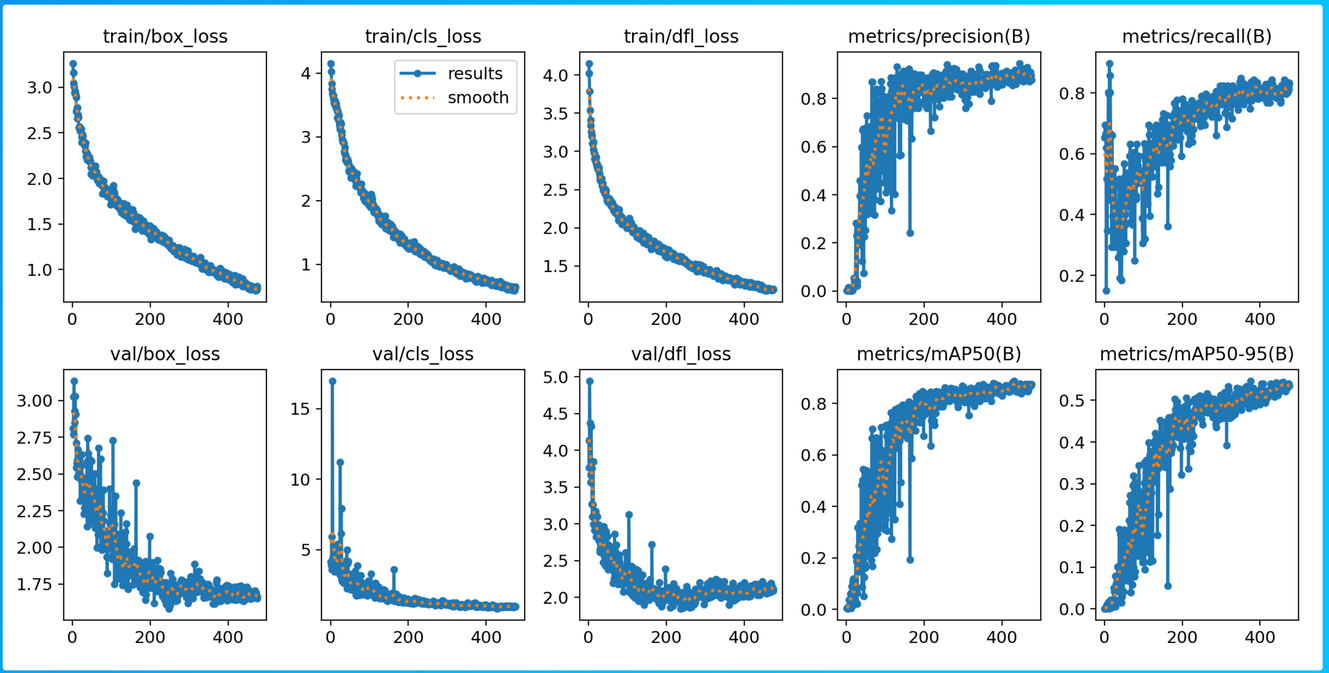
área da curva P × R com IoU ≥ 0,5

54,6%

mAP@50-95

média com IoU de 0,5 a 0,95

Métricas no conjunto de validação (144 imagens), calculadas pelo Ultralytics a cada época.

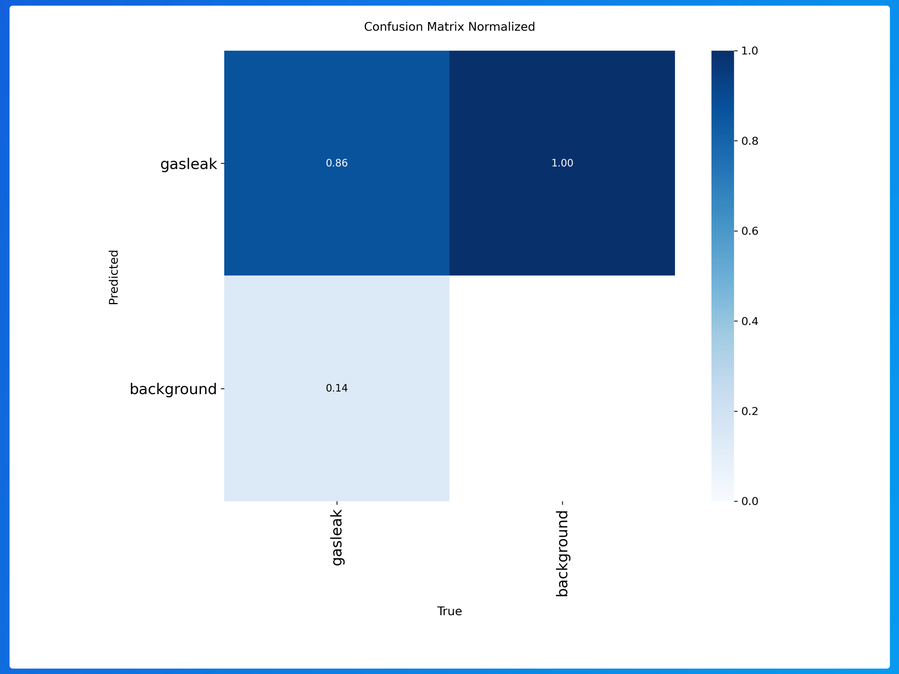


Leitura: as perdas de treino caem até o fim, mas as de validação se estabilizam em cerca do dobro (box: 1,66 × 0,77 na última época), um indício de sobreajuste.

TREINAMENTO: RESULTADOS

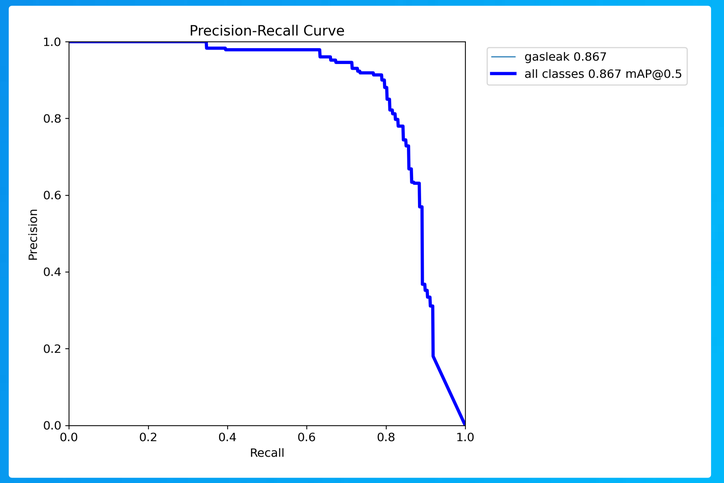
FAESA CENTRO UNIVERSITÁRIO

Onde o modelo acerta e onde erra

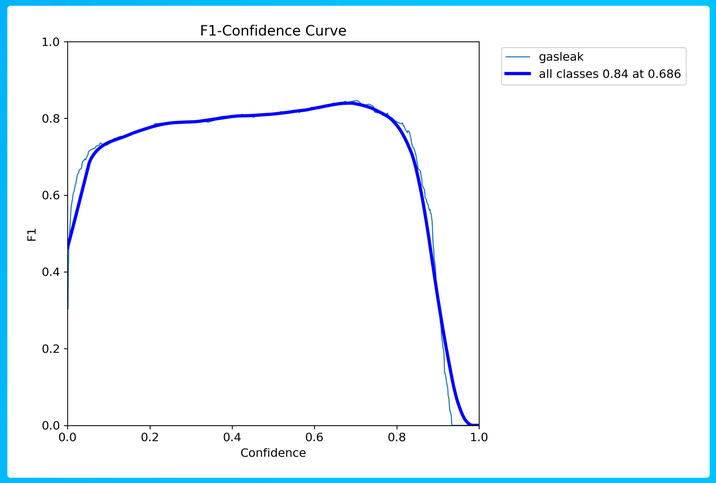


Matriz de confusão normalizada

Colunas: classe real · Linhas: classe prevista



Curva precisão × recall (mAP@50 ≈ 0,87)



Curva F1 × confiança (máx. 0,84 em 0,69)

O que os gráficos mostram

- 86% das plumas reais são detectadas e 14% passam despercebidas (limiar 0,25): o erro dominante é o falso negativo.
- O melhor equilíbrio (F1 = 0,84) ocorre com confiança ≈ 0,69; em segurança, um limiar menor aumenta o recall.





RESULTADOS:
DETECÇÃO EM VÍDEOS OGI

FAESA
CENTRO UNIVERSITÁRIO



IMAGENS DE TESTE

Vazamentos detectados

- Imagens separadas para demonstrar o modelo em cenas variadas
- A caixa marca a pluma detectada e o número é a confiança do modelo (0 a 1)
- Limiar de confiança usado: 0,5
- Nos vídeos, o mesmo modelo roda em cada quadro

RESULTADOS: DETECÇÃO EM IMAGENS DE TESTE

FAESA CENTRO UNIVERSITÁRIO

Do protótipo a um sistema de monitoramento

1 Modelo e dados

- Transfer learning a partir de pesos pré-treinados (yolov8s.pt ou YOLO11s)
- Separar treino, validação e teste por vídeo: hoje 9 de 14 fontes da validação também estão no treino
- Incluir imagens negativas: vapor, fumaça da tocha, névoa e distorção térmica

2 Detecção em vídeo

- Alarme só com detecção em N de M quadros, reduzindo falsos alarmes
- Rastreamento das plumas entre quadros (ByteTrack)
- Segmentação: área da pluma como indicador de severidade

3 Integração IIoT e embarcados

- Inferência na borda com ONNX/TensorRT (Jetson ou Raspberry Pi 5)
- Alarmes via MQTT/OPC UA para o sistema supervisório
- Confirmação com sensor de metano (ESP32 + MQ-4)

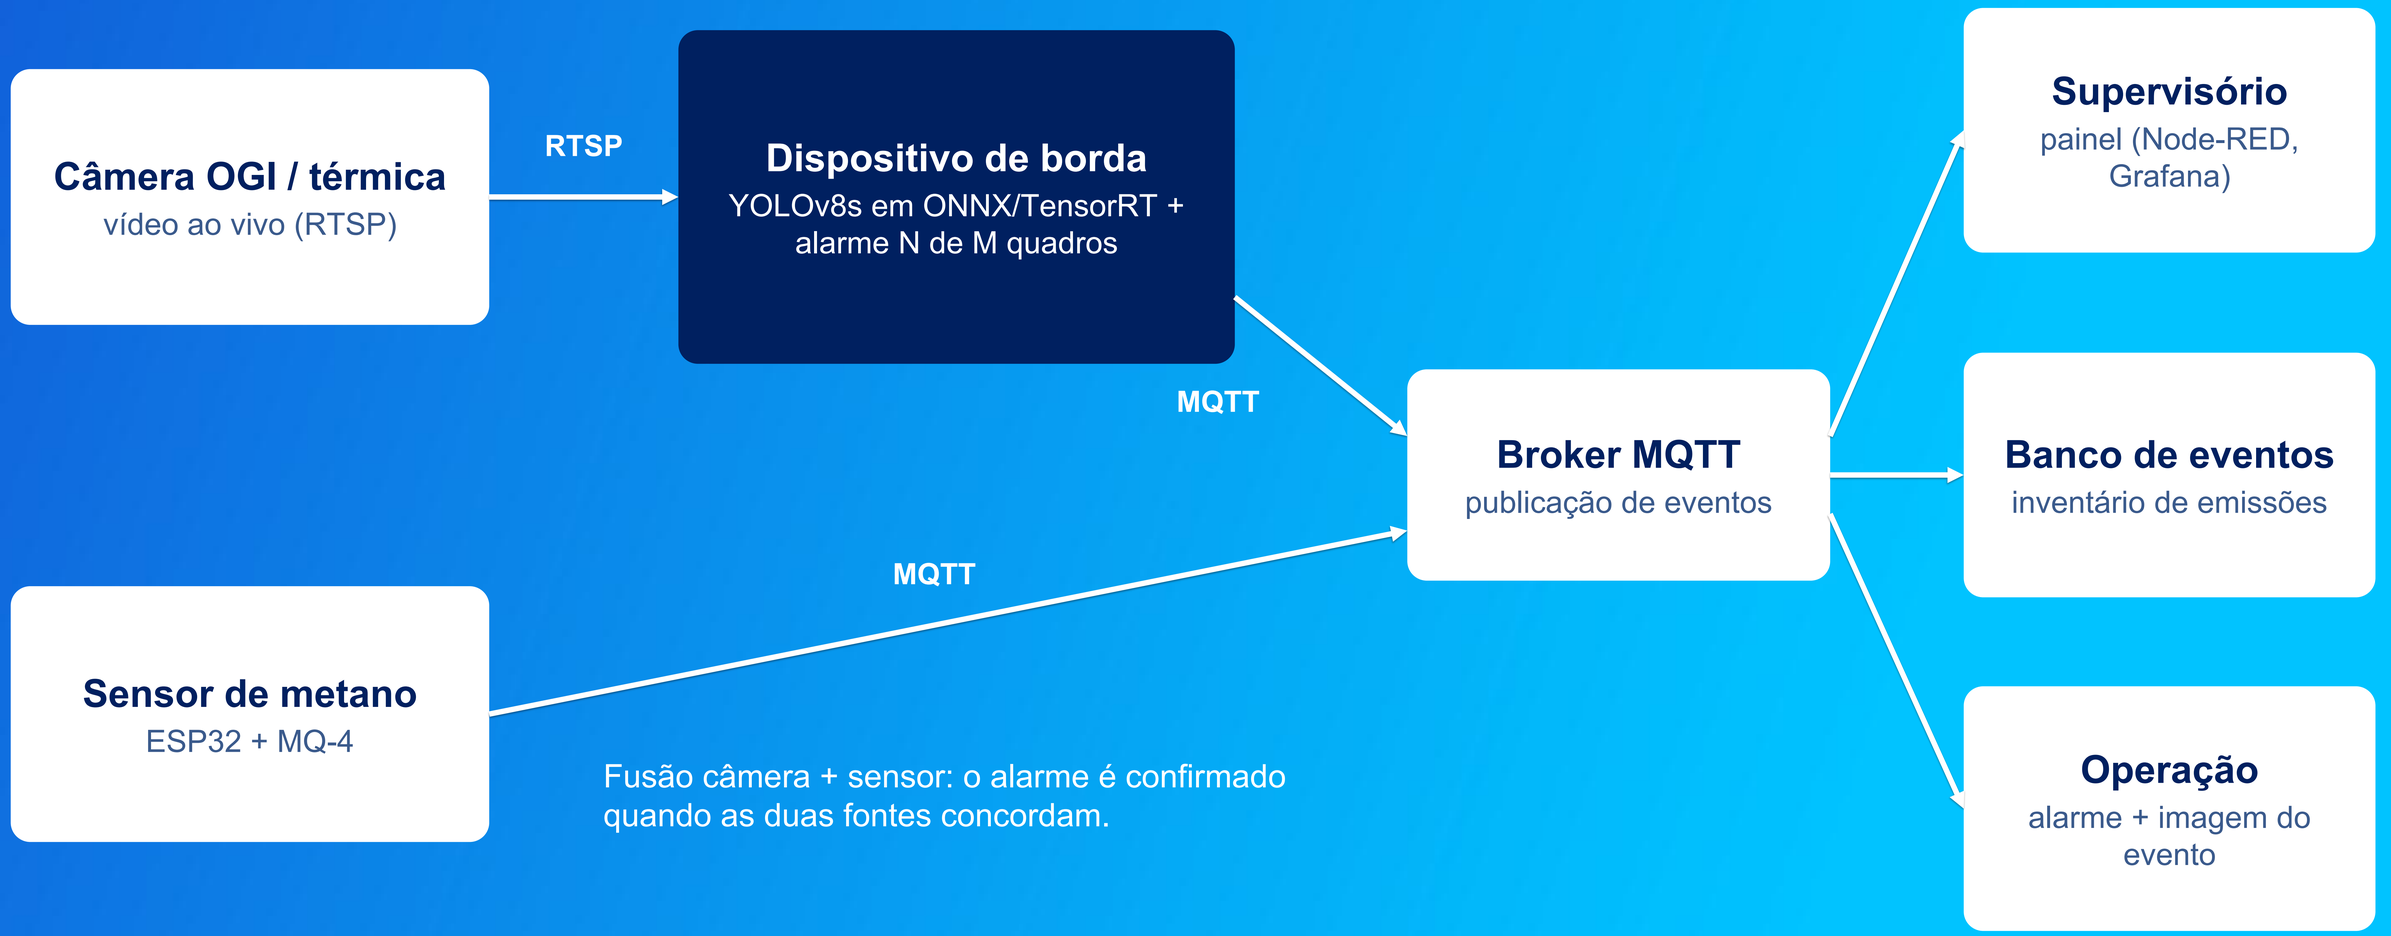
4 Operação e descarbonização

- Limiar escolhido pela curva F1/recall: em segurança, não detectar custa mais que um falso alarme
- Registro de eventos (duração e área) para o inventário de emissões fugitivas
- Apoio a programas de detecção e reparo de vazamentos (LDAR)

PRÓXIMOS PASSOS:
MELHORIAS PROPOSTAS

FAESA
CENTRO UNIVERSITÁRIO

Proposta de arquitetura integrada (próxima etapa)



PRÓXIMOS PASSOS: ARQUITETURA DA SOLUÇÃO INTEGRADA

FAESA
CENTRO UNIVERSITÁRIO

Código, dados e resultados abertos

Aponte a câmera para abrir o repositório

Repositório no GitHub
github.com/RoberliSchuina/Projeto-Integrador-4-Gasleak

Notebook de treinamento (Google Colab)
colab.research.google.com/drive/1HVmY2yG92IVbBIlGE5xDI1HWjclknZVJ

Dataset de detecção (Roboflow Universe)
universe.roboflow.com/roberli/gas-leak-x7van-qfi52

Dataset de segmentação (Roboflow Universe)
universe.roboflow.com/roberli/gas-leak-ka6fi-uahui

Vídeos, pesos e arquivos (Google Drive)
drive.google.com/drive/folders/1fbmdwq0HorSvJ0A4UIHge39IE8-hVHQb



OBRIGADO!

FAESA
CENTRO UNIVERSITÁRIO